

1 | 통계 모델과 확률 분포

1 통계 모델과 확률 분포

- ▶ 머신 러닝
- ▶ 일반화 선형 모델과 기저함수
- ▶ 주요 기저 함수
- ▶ 기타 비선형 함수

2 확률 기반


- ▶ 일반적인 사건(Event)의 발생들은 확률로 표현 가능
 - 동전을 던질 때 앞면과 뒷면 어느 방향이 나올 것인가
 - 태풍이 올 때 날씨는 어떨까?
- ▶ 회귀 분석 시 설명 변수와 목적 변수들 간에 선형함수를 통한 피팅 방법 사용
- ▶ 피팅을 위한 오차 함수 설정 시 확률이 관여됨
 - 두 변수 간의 측정 결과에 따른 측정 오차가 확률 분포를 따름
 - 측정오차는 정규 분포 등의 분포로 표현

2 확률 기반

▶ 확률 분포 모델

- 설명 변수와 목적 변수가 갖는 어떤 확률에 근거한 관계
- 임의의 분포를 갖는 오차로 표현

[측정 오차와 정규 분포]



* 출처 : 처음 배우는 인공지능, 다다 사토시, 한빛미디어, 2017

3 머신 러닝

▶ 학습


- 신경망에서 데이터 입력을 통해 스스로 네트워크의 가중치를 변화시키는 것

▶ 머신 러닝

- 신경망의 학습처럼 ‘기계가 학습한다’는 개념을 의미하는 용어
- 입력 데이터의 특성과 분포 경향 등에서 자동으로 데이터를 나누거나 재구성
- 통계 기반 머신 러닝에서는 확률 개념이 크게 관여

3 머신 러닝

▶ 회귀 분석이 머신 러닝 및 신경망과의 연관 여부



* 출처 : 처음 배우는 인공지능, 다다 사토시, 한빛미디어, 2017

3 머신 러닝

- ▶ 입력 데이터의 회귀 분석 시 주로 데이터 식별 및 예측에 목적을 둠
- ▶ 따라서 데이터를 선형 결합으로 나타내는 특성 이용
- ▶ 회귀 분석 지도학습
 - 정답 정보가 결합된 학습 데이터(또는 훈련 데이터)로 데이터의 특징을 모델링
- ▶ 신경망 학습
 - 선형 분리로 변환하는 특성 이용
 - 선형 분리가 가능하면 회귀 분석과 같은 선형 결합 방법 사용

3 머신 러닝

▶ 자율 학습

- 신경망을 사용하지 않는 경우
 - ✓ 입력 데이터의 정답을 모르는 상태에서 사용
 - ✓ 클러스터 분석, 차원 압축, 밀도 추정 등에 해당
- 데이터 마이닝
 - ✓ 식별, 예측, 클러스터 분석 등 실행 시데이터의 새로운 특징을 찾아내는 작업

3 머신 러닝

▶ 데이터 마이닝

- 분류(Classification)

- : 일정한 집단에 대한 특징 정의를 통해
분류 및 구분을 추론

- 군집화(Clustering)

- : 구체적인 특성을 공유하는 군집 검색
 - : 군집화는 미리 정의된 특성에 대한 정보를 가지지 않
는다는 점에서 분류와 다름

- 연관성(Association)

- : 동시에 발생한 사건 간의 관계를 정의

3 머신 러닝

▶ 데이터 마이닝

▪ 연속성(Sequencing)

: 특정 기간에 걸쳐 발생하는 관계를 규명,
기간의 특성을 제외하면 연관성 분석과 유사

▪ 예측(Forecasting)


: 대용량 데이터 집합 내의 패턴을 기반으로 미래 예측

4 기저 함수


▶ 정규 직교 기저

- 좌표축 각각이 직교하는 선형 독립 상태에서 벡터로 나타내는 좌표축
- 차원 수 만큼 표현이 가능하여 3차원 이상도 표현

[정규 직교 기저]



2차원($ax + by = c$)



3차원($ax + by + cz = d$)


※ 출처 : 처음 배우는 인공지능, 다다 사토시, 한빛미디어, 2017

4 기저 함수

- ▶ 회귀 분석을 정규 직교 기저로 설명하면, 선형 독립인 설명 변수의 합에 있는 목적 변수를 표현하는 것
- ▶ 설명 변수가 선형 독립인 경우만 사용
- ▶ 기저 함수
 - 설명 변수를 함수 형태로 나타낸 것
- ▶ 기저 함수 사용 시 개념
 - 일반화 선형 모델
 - : 정규 분포 이외의 분포를 다루는 모델
 - 혼합 정규 모델
 - : 혼합 정규 분포를 다루는 모델
 - : 기저 함수와 기저 함수의 선형 결합으로 표현된 모델

4 기저 함수

[혼합 정규 분포]



- 검은색 선
: 진한 붉은색 선과
연한 붉은색 선의
정규 분포 밀도
함수의 합
- 원
: 검은색 선에
정규 분포를 따르는
오차를 추가한 값


※ 출처 : 처음 배우는 인공지능, 다다 사토시, 한빛미디어, 2017

2 | 주요 기저 함수

1 주요 기저 함수

- ▶ 기저 함수는 확률 분포에 따라 연속 확률 분포와 이산 확률 분포로 나뉨

[모델이 되는 주요 함수]



※ 출처 : 처음 배우는 인공지능, 다다 사토시, 한빛미디어, 2017

2 정규 분포

- ▶ 가장 많이 사용하는 일반적인 분포 개념
- ▶ 가우스 분포라고도 함
- ▶ 실험의 측정 오차나 사회 현상 등
자연계 현상은 정규 분포를 따른 경향이 있음
- ▶ 정규 분포를 엄격히 따르지 않아도 계산이나
모델의 단순화를 위해 데이터 분포를 정규 분포로
가정하는 경우가 많음

2 정규 분포

▶ $f(x)$: 정규 분포, μ : 평균(기대값), σ : 표준 편차, σ^2 : 분산


[정규 분포 식]

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

$$E(x) = \mu$$

$$V(x) = \sigma^2$$

[정규 분포 형태]



※ 출처 : 처음 배우는 인공지능, 다다 사토시, 한빛미디어, 2017

3 감마분포

- ▶ 특정 수의 사건이 일어날 때까지 걸리는 시간에 관한 연속 확률 분포
- ▶ 감마 함수 「는 자연수 집합 N 이 주어졌을 때 팩토리얼 $N!$ 과 동일
- ▶ 모양 매개 변수가 k 고 크기 매개 변수가 θ 일 때
 - 평균 : $k\theta$
 - 분산 : $k\theta^2$

3 감마분포

▶ $k = 1$ 일 때 지수분포, k 가 정수일 때 얼랑 분포, k 가 반정수($(2n - 1)/2$)고 θ 가 2일 때는 카이 제곱 분포라 함


[감마 분포 식]

$$f(x) = \frac{e^{-x/\theta}}{\Gamma(k)\theta^k}$$

$$E(x) = k\theta$$

$$V(x) = k\theta^2$$

[감마 분포 형태]



- 검은색
: $k: 1 \theta: 2.0$
- 붉은색 실선
: $k: 2 \theta: 2.0$
- 갈색선
: $k: 3 \theta: 2.0$

※ 출처 : 처음 배우는 인공지능, 다다 사토시, 한빛미디어, 2017

4 지수분포

- ▶ 감마 분포의 특별한 형태로
사건이 일어나는 시간 간격의 확률 분포
- ▶ 푸아송 분포와도 연관
- ▶ λ : 단위 시간에 일어나는 평균 회수
- ▶ 평균 : ${}^1/\lambda$
- ▶ 분산 : ${}^1/\lambda^2$

4

지수 분포


[지수 분포 식]

$$f(x) = \lambda e^{-\lambda x}$$

$$E(x) = 1/\lambda$$

$$V(x) = 1/\lambda^2$$

[지수 분포 형태]



※ 출처 : 처음 배우는 인공지능, 다다 사토시, 한빛미디어, 2017

5 라플라스 분포

- ▶ 보통의 정규분포보다 최고점이 더 높은 분포
- ▶ 생물학, 재무, 경제 분야에서 데이터를 모형화 시 사용
- ▶ 평균 : μ
- ▶ 분산 : $2\sigma^2$

5 라플라스 분포


[라플라스 분포 식]

$$f(x) = \frac{1}{2\sigma} \exp\left(-\frac{|x - \mu|}{\sigma}\right)$$

$$E(x) = \mu$$

$$\text{V}(x) = 2\sigma^2$$

[라플라스 분포 형태]



※ 출처 : 처음 배우는 인공지능, 다다 사토시, 한빛미디어, 2017

6 베타 분포

- ▶ 2개의 변수를 갖는 특수 함수인 베타 함수를 이용한 분포
- ▶ 베타 함수를 $B(\alpha, \beta)$ 로 나타낼 때,
 $\alpha > 0, \beta > 0, 0 \leq x \leq 1$ (x 는 설명 변수)라는 조건 설정
- ▶ 매개변수 α, β 를 바꾸면 다양한 분포로 표현 가능
- ▶ 베이즈 통계학에서는 사전 분포 모델로
이용하는 경우가 많음

6 베타 분포

[베타 분포 식]


$$f(x) = \frac{x^{\alpha-1}(1-x)^{\beta-1}}{B(\alpha, \beta)}$$

$$E(x) = \frac{\alpha}{\alpha + \beta}$$

$$V(x) = \frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}$$

[베타 분포 형태]

$$B(\alpha, \beta) = \Gamma(\alpha + \beta)/[\Gamma(\alpha)\Gamma(\beta)]$$



※ 출처 : 처음 배우는 인공지능, 다다 사토시, 한빛미디어, 2017

7

디리클레 분포

- ▶ 베타 분포를 다변량으로 확장한 것
- ▶ 다변량 베타 분포라고도 함
- ▶ k 는 2 이상의 자연수, α 는 매개변수, $B(\alpha)$ 는 베타 함수,
 Γ 는 감마 함수

[디리클레 분포 식]

$$f(x) = \frac{1}{B(\alpha)} \prod_{i=1}^k x_i^{\alpha_{i-1}} \quad B(\alpha) = \frac{\prod_{i=1}^K \Gamma(\alpha_i)}{\Gamma(\prod_{i=1}^K \alpha_i)}$$

※ 출처 : 처음 배우는 인공지능, 다다 사토시, 한빛미디어, 2017

7

디리클레 분포

- ▶ 연속 함수지만 2차원 평면에서는 연속 함수로 표현 불가
- ▶ 어떤 현상이 일어나는 횟수를 확률 변수로 두는 분포가
다항 분포
- ▶ 디리클레 분포는 확률 자체를 확률 변수로 두는 분포로
자연어 처리 등에 많이 사용

8

이항 분포

- ▶ 베르누이 시행
 - 두 가지 경우 중 어느 하나가 나오는 가와 같은 실험
- ▶ 이항 분포
 - 베르누이 시행을 여러 번 반복했을 때 확률 분포
- ▶ 정규 분포나 푸아송 분포와 비슷

8

이항 분포


[이항 분포 식]

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}$$

$$E(x) = np$$

$$V(x) = np(1 - p)$$

[이항 분포 형태]



※ 출처 : 처음 배우는 인공지능, 다다 사토시, 한빛미디어, 2017

8 이항분포

- ▶ X 는 확률 분포, 확률 p 로 성공하는 실험에 있어
 p^k 는 k 번 성공할 확률, n 번 실행하는 경우
 ${}_nC_k$ 의 조합만큼 성공할 확률이 나타날 가능성이 있음
- ▶ 실패 회수의 확률과 함께 계산 시 n 번의 독립된 시도에서
 k 회 성공할 확률을 나타낼 수 있음

9 음이항 분포

- ▶ r 번 성공하는데 필요한 시행 회수 k 의 분포
- ▶ 생명 과학 분야에 많이 사용


[음이항 분포 식]

$$P(X = k) = \binom{k-1}{r-1} p^r (1-p)^{k-r}$$

$$E(x) = r/p$$

$$V(x) = r(1-p)/p^2$$

[음이항 분포 형태]



※ 출처 : 처음 배우는 인공지능, 다다 사토시, 한빛미디어, 2017

10 푸아송 분포

- ▶ 일정 시간 간격에 걸쳐 평균 λ 번 일어나는 현상이 k 번 발생할 확률 분포 X
- ▶ 푸아송 분포
 - 단위 시간에 사건이 일어날 확률
- ▶ 지수분포
 - 사건이 일어난 후 다시 발생할 때까지의 시간 간격에 관한 확률 밀도
- ▶ 푸아송 분포와 지수 분포는 같은 사건의 발생 확률을 다른 측면에서 보는 것

10 푸아송 분포


[푸아송 분포 식]

$$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}$$

$$E(x) = \lambda$$

$$V(x) = \lambda$$

[푸아송 분포 형태]



※ 출처 : 처음 배우는 인공지능, 다다 사토시, 한빛미디어, 2017

11

카이제곱 분포

- ▶ 감마 분포의 특별한 형태
- ▶ 통계적 추론에서는 카이제곱 검정으로 자주 이용
- ▶ 집단을 몇 가지로 나눴을 때 크기가 작은 집단에 보편성이 있는지 확인
- ▶ 임상 실험이나 사회 과학 설문 조사 등에 자주 사용
- ▶ 평균 k 는 2 이상의 자연수, x 는 설명 변수, Γ 는 감마 함수

11 카이제곱 분포


[카이제곱 분포 식]

$$f(x) = \frac{(\frac{1}{2})^{k/2}}{\Gamma(k/2)} x^{k/2-1} e^{-x/2}$$

$$E(x) = k$$

$$V(x) = 2k$$

[카이제곱 분포 형태]



※ 출처 : 처음 배우는 인공지능, 다다 사토시, 한빛미디어, 2017

12 초기화 분포

- ▶ 반복하지 않는 시도에서 사건이 발생할 확률 분포
- ▶ 예)
 - 빨간 구슬과 흰 구슬이 들어 있는 주머니에서 구슬을 빼는 시도를 n 번 할 때 빨간 구슬 k 개를 꺼낼 수 있는 확률을 구할 수 있음
 - 구슬 전체 개수는 N , 원하는 구슬을 꺼낸 전체 성공 회수는 K

12 초기하 분포


[초기하 분포 식]

$$P(X = k) = \binom{n}{k} \binom{N-n}{K-k} / \binom{N}{k}$$

$$E(x) = nK/N$$

$$\text{V}(x) = (N-n)m(N-K)K/(N-1)N^2$$

[초기하 분포 형태]



※ 출처 : 처음 배우는 인공지능, 다다 사토시, 한빛미디어, 2017

13 코시 분포


- ▶ 로렌츠 분포라고도 함
- ▶ 물리학에서는 브라이트-위그너 분포라고 함
- ▶ 분광학에서의 공명 현상 등 전자파와
방사선의 스펙트럼 분석 등에서 자주 사용
- ▶ π 는 원주율, γ 는 척도 모수
(확률 분포가 퍼져 있는 정도를 결정하는 집단의 수)
- ▶ 정규 분포와 비슷한 모양
- ▶ 그래프가 서서히 완만해 지며 중심이 그래프 아래로 잡힘

13 코시 분포

[코시 분포(로렌츠분포) 식]

$$f(x) = \frac{1}{\pi\gamma \left\{ 1 + (\frac{x - \mu}{\gamma})^2 \right\}}$$

[코시 분포 형태]



※ 출처 : 처음 배우는 인공지능, 다다 사토시, 한빛미디어, 2017

14 로지스틱 분포

- ▶ 확률 분포의 확률 변수가 특정값보다 작거나 같은 확률을 나타내는 누적 분포 함수가 로지스틱 함수인 분포
- ▶ 형태는 정규 분포와 비슷하지만 그래프의 아래가 길어 평균에서 멀어지더라도 정규 분포처럼 곡선이 내려가지 않음
- ▶ s 는 표준 편차, μ 는 평균, π 는 원주율

14 로지스틱 분포

[로지스틱 분포 식]

$$f(x) = \frac{1}{s(1 + e^{\frac{x-\mu}{s}})^2}, s > 0$$

$$E(x) = \mu$$

$$V(x) = s^2\pi^2/3$$

※ 출처 : 처음 배우는 인공지능, 다다 사토시, 한빛미디어, 2017

15 베이불 분포

- ▶ 물체의 부피와 강도의 관계를 나타내는 분포
- ▶ 기기의 수명과 고장 시간 등의 신뢰성을 나타내는 지표로 이용
- ▶ $k(m)$ 는 실행 회수, $\lambda(\eta)$ 는 단위 시간에 일어나는 평균 회수

15 베이불 분포


[베이불 분포 식]

$$f(x) = \frac{m}{\eta} \left(\frac{x}{\eta}\right)^{m-1} \exp\left\{-\left(\frac{x}{\eta}\right)^m\right\}$$

$$E(x) = \eta \Gamma(1 + 1/m)$$

$$V(x) = \eta^2 [\Gamma(1 + 2/m) - (\Gamma(1 + 1/m))^2]$$

[베이불 분포 형태]



※ 출처 : 처음 배우는 인공지능, 다다 사토시, 한빛미디어, 2017

16

손실 함수와 경사 하강법

- ▶ 회귀 분석을 사용하려는 함수가 존재할 때,
회귀 분석은 오차를 제곱한 것의 합계인 함수를
목적 함수로 설정
- ▶ 목적 함수가 최소값이 되도록 계산
- ▶ 목적 함수와 비슷한 함수로 손실 함수 사용

16

손실 함수와 경사 하강법

▶ 손실 함수의 최소값 산출 식

- 경사 하강법


- ✓ 가중치 벡터 w 의 함수 L 로 작성
- ✓ 손실 함수를 어떤 점 w_i 로 편미분 한 것을 L 의 기울기를 $\nabla L(w)$
- ✓ 기울기 값이 $\nabla L(w^*) = 0$ 이 될 때의 w^* 가 구하려는 가중치

- 최대 가능성 방법

16

손실 함수와 경사 하강법

[경사 하강법]



※ 출처 : 처음 배우는 인공지능, 다다 사토시, 한빛미디어, 2017

3 | 베이즈 통계학

1 베이즈 통계학

- ▶ 베이즈 정리
- ▶ 로짓 함수
- ▶ 최대 가능성 추정
- ▶ EM 알고리즘
- ▶ 베이즈 판별 분석

2 베이즈 정리

- ▶ 조건부 확률에 관한 법칙
- ▶ 두 종류의 조건부 확률 사이의 관계 정의

[베이즈 정리]

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

$$P(A_i|B) = \frac{P(B|A_i)P(A_i)}{\sum_{j=1}^5 P(B|A_j)P(A_j)}$$

- B 라는 조건 아래 A 가 일어날 조건부 확률의 정의
- 일반적인 형태의 베이즈 정리 식
- A_1, A_2, \dots, A_n 이 서로 관계가 없는 사건일 때 사용할 수 있는 베이즈 정리 식

※ 출처 : 처음 배우는 인공지능, 다다 사토시, 한빛미디어, 2017

2 베이즈 정리

▶ 승산

- 확률 p 가 있을 때 $p/(1-p)$ 를 계산한 수치
- 수치가 높을 수록 이길 가능성이 작아짐
- 이 값의 로그를 취한 것을 로짓 함수
- 로지스틱 회귀 등에서 이용

▶ 승산 비

- 승산을 2개 사용해 비율을 취한 것
- 두 집단에서 두 사건이 일어 났을 때 해당 사건이 일어나기 쉬운 정도
- 임상 시험에서 투여한 약물의 효과가 어느 정도인가
- 특정 두 시기에서 남녀의 인구 추세에 큰 차이가 있는지 등의 지표로 사용

2 베이즈 정리

▶ 승산 비

[승산비의 베이즈 정리 식]

$$\left(\frac{P(A|B)}{1 - P(A|B)} \right) \Bigg/ \frac{P(A)}{1 - P(A)} = \frac{P(B|A)}{P(B|A^c)}$$

- * B 라는 조건 아래 A 가 일어날 조건부 확률의 정의

※ 출처 : 처음 배우는 인공지능, 다다 사토시, 한빛미디어, 2017

2 베이즈 정리

▶ 예1) 질병 검사의 양성 적중율

- 질병 검사에서 질병에 걸릴 확률이 0.01
- 병에 걸린 사람이 검사하면 0.99의 비율로 양성
- 건강한 사람도 0.1의 비율로 양성이 된다고 가정

[양성 적중율의 계산식]

$$P(\text{질병}|\text{양성}) = \frac{P(\text{양성}|\text{질병})P(\text{질병})}{P(\text{양성})} = \frac{0.99 * 0.01}{0.01 * 0.99 + 0.99 * 0.1} = 0.091$$

※ 출처 : 처음 배우는 인공지능, 다다 사토시, 한빛미디어, 2017

2 베이즈 정리

▶ 예2) 뺑소니 택시의 색상

- 뺑소니 택시 사고 발생 시 목격자 증언에 따라 택시 색이 파란색이라고 증언
- 거리에는 파란색과 녹색 두 종류 차량이 있으며 각각 15%, 85%의 비율 차지
- 비슷한 상황으로 실험한 결과 목격자가 파란색이라고 했는데 실제 파란색일 비율 80%일 때 실제 녹색일 확률은?

* 출처 : 처음 배우는 인공지능, 다다 사토시, 한빛미디어, 2017

2 베이즈 정리

▶ 예2) 뺑소니 택시의 색상

[뺑소니 택시 색의 계산식]

$$\frac{P(\text{파란색}|\text{목격})}{P(\text{녹색}|\text{목격})} = \frac{P(\text{목격}|\text{파란색})}{P(\text{목격}|\text{녹색})} * \frac{P(\text{파란색})}{P(\text{녹색})} = \frac{0.8}{0.2} * \frac{0.15}{0.85} = \frac{12}{17}$$

$$P(\text{파란색}|\text{목격}) + P(\text{녹색}|\text{목격}) = 1 \text{에서}$$

$$P(\text{녹색}|\text{목격}) = \frac{12}{12 + 17} \cong 0.59$$

※ 출처 : 처음 배우는 인공지능, 다다 사토시, 한빛미디어, 2017


3 최대 가능도 방법과 EM 알고리즘

- ▶ 관측 데이터가 의미 있는 값과 노이즈로 구성된 경우
- ▶ 의미 있는 값을 구할 때 최소제곱법 사용 시 손실 함수 설정
- ▶ 손실 함수 대신 가능도 함수 설정
- ▶ 가능도 함수가 최대가 되는 θ 설정 시 θ 는 최대 가능도 추정량이라 함
- ▶ 엔트로피가 높은 상태, 즉 노이즈가 가장 균형 있게 흩어져 있는 상태를 최대가능도 추정량으로 정해서 의미 있는 데이터를 구할 수 있음

3 최대 가능도 방법과 EM 알고리즘

- ▶ 가능도 함수는 적분 형태가 나타낼 때가 많아
로그 가능도 방정식 형태로 답을 구함

[손실 함수와 가능도 함수]



[로그 가능도 방정식]

$$\frac{\partial \log L(\theta)}{\partial \theta_1} = \frac{\partial \log L(\theta)}{\partial \theta_2} = \dots = \frac{\partial \log L(\theta)}{\partial \theta_k} = 0$$

※ 출처 : 처음 배우는 인공지능, 다다 사토시, 한빛미디어, 2017


3 최대 가능도 방법과 EM 알고리즘

- ▶ 복잡한 가능도 함수에서 최대가능도 추정량을 직접 구할 수 없을 수 있음
- ▶ 반복 계산으로 구하는 방법 선택
- ▶ 의미 있는 값 x 를 완전 데이터라고 하며 관찰할 수 있는 데이터 y 는 불완전 데이터라고 함

3 최대 가능도 방법과 EM 알고리즘

- ▶ x 에 추가되는 어떤 작용 $s(x)$ 의 정보가 없으면 데이터 x 를 한 가지 값으로 구할 수 없음

[완전 데이터와 불완전 데이터의 관계도]



※ 출처 : 처음 배우는 인공지능, 다다 사토시, 한빛미디어, 2017

3 최대 가능도 방법과 EM 알고리즘


- ▶ EM(Expectation Maximization) 알고리즘
 - 숨겨진 변수를 포함하는 모델에 사용하는 가상 데이터 전체의 가능도 함수를 바탕으로 불완전한 데이터에서 최대가능도 추정량을 구하는 방법
 - 아래쪽 경계를 결정하기 위한 θ 에 의존하는 볼록 함수 Q 를 결정하는 E 단계와 Q 에서의 θ 를 극대화하는 M 단계를 반복 실행해 로그 가능도 함수의 최대값을 탐색
 - E 단계에서 구하는 Q 는 사후 분포

3 최대 가능도 방법과 EM 알고리즘

[EM 알고리즘 식]

- E(Expectation) 단계
: $Q(\cdot | \theta_m)$ 을 산출
 θ_m 은 $\hat{\theta}_{MLE}$ 의 m 번째 근사치
- M(Maximization) 단계
: $\theta_{m+1} = [\text{argmax}]_{\theta} Q(\theta | \theta_m)$

[EM 알고리즘 형태]




※ 출처 : 처음 배우는 인공지능, 다다 사토시, 한빛미디어, 2017

4 베이즈 추론

- ▶ 데이터의 모집단 분포는 유일하지 않음
- ▶ 관측하지 않은 데이터를 다룬다는 의미
- ▶ 사전 분포(Prior Distribution) 혹은
주관 분포(Subjective Distribution)
 - 추론해야 하는 대상이 매개변수 θ 일 때
확률 밀도 함수 $\pi(\theta)$

4 베이즈 추론



$$f(\theta|x) = \frac{1}{f(x)} * f(x|\theta)\pi(\theta) \propto f(x|\theta)\pi(\theta)$$

$$f(x) = \int f(x|\theta)\pi(\theta) d\theta$$

※ 출처 : 처음 배우는 인공지능, 다다 사토시, 한빛미디어, 2017

4 베이즈 추론

▶ 베이즈 추정량

- 사후 분포의 평균 제곱 오차를 최소화하는 값
- 사후 분포의 평균값

[베이즈 추정량 식]

$$\widehat{\theta}(x) = \arg \min_{\theta} \int_{\theta} |t - \theta|^2 f(\theta|x) d\theta$$

※ 출처 : 처음 배우는 인공지능, 다다 사토시, 한빛미디어, 2017

4 베이즈 추론

▶ 사후 메디안 추정량

- 사후 분포의 평균 절대 오차를 최소화하는 값
- 사후 분포의 중간값

[사후 메디안 추정량의 식]

$$\hat{\theta}(x) = \arg \min \int_{-\infty}^{\infty} |t - \theta| f(\theta|x) d\theta$$

※ 출처 : 처음 배우는 인공지능, 다다 사토시, 한빛미디어, 2017

4 베이즈 추론

▶ MAP 추정량

- 사후밀도를 최대화하는 θ 값
- 사후 최빈값 추정량이라고도 함
- MAP은 최대 사후 확률이라고도 함

[MAP 추정량 식]

[MAP 추정량 형태]

$$\hat{\theta}(x) = \arg_{\theta} \max \frac{f(x|\theta)\pi(\theta)}{f(x)}$$



※ 출처 : 처음 배우는 인공지능, 다다 사토시, 한빛미디어, 2017

4 베이즈 추론

▶ 결례 사전 분포

- 사전 분포 $\pi(\theta)$ 와 사후 분포 $f(\theta|x)$ 가 같은 유형의 분포를 보일 때를 결례 사전 분포라 함
- 사후 분포를 다루기 쉬운 특징
- $\pi(\theta|\alpha)$ 처럼 추가 매개변수가 들어가면 사후 분포에서는 $f(\theta|x,\alpha)$ 같은 형태로 표현
- α 를 하이퍼 파라미터라고 함

[사후 예측분포 식]

$$f(x|D) = \int f(x|\theta)f(\theta|D) d\theta$$


※ 출처 : 처음 배우는 인공지능, 다다 사토시, 한빛미디어, 2017

4 베이즈 추론

▶ 결례 사전 분포

- 사후 예측분포 $f(x | D)$ 는 진정한 밀도 함수 $f(x)$ 에 가까운 것이라는 개념에 기반을 둔 것
- 따라서 데이터 D 를 기준으로 나타나는 다음 데이터 x 값을 예측하는 형태가 됨

[사후 예측 분포의 형태]



매개 변수 X 값을
사후분포에서 선택한 후
이를 이용해
 Y 값을 계산해서
예측분포를 얻음

* 출처 : 처음 배우는 인공지능, 다다 사토시, 한빛미디어, 2017

5 베이즈 판별 분석

▶ 베이즈 추론의 예

- 데이터 x 가 어떤 모집단분포에 유래했는지 파악하는데 사용
- 선형 판별 분석
: 지도 학습의 훈련 데이터를 바탕으로 결정하는 경우가 많음

▶ 베이즈 통계학 개념이 포함된 요소를 추가한 것이 베이즈 판별 분석

5 베이즈 판별 분석

- ▶ N 가지 종류의 데이터 x 와 추론 대상 매개변수 i 가 있는 모집단분포 $f(x|i)$ 와 사전 분포 $\pi(i)$ 로부터 사후 확률이 최대가 되는 모집단 분포 $f(x|i)$ 의 유래를 판정

[베이즈 판별 분석 식]

$$f(i|x) = \frac{f(x|i)\pi(i)}{\sum_{j=1}^n f(x|j)\pi(j)} \propto f(x|i)\pi(i)$$

※ 출처 : 처음 배우는 인공지능, 다다 사토시, 한빛미디어, 2017