

# 1 | 자율 학습

## 1 자율 학습

- ▶ 학습이라는 것은 계산을 반복하면서 가중치 계수를 업데이트하는 작업
- ▶ 가중치 계수 업데이트를 통해 모델이 되는 기저 함수와 분포에 접근하는 것을 의미
- ▶ 자율 학습
  - 정답 정보가 없는 상태에서 학습을 통해 모델을 만드는 것
  - 데이터가 어떻게 구성되었는지를 알아내는 문제 범주에 속함
- ▶ 특징
  - 통계의 밀도 추정과 연관
  - 데이터의 주요 특징을 요약하고 설명

## 2 데이터 마이닝

### ▶ 정의

- 대규모로 저장된 데이터 안에서 체계적이고 자동적으로 통계적 규칙이나 패턴을 찾아내는 것
- KDD(Knowledge Discovery in Databases)

### ▶ 방법론

- 통계학적 방법론: 통계학 쪽에서 발전
- 기술적인 방법론: 인공지능 진영에서 발전

### ▶ 신용 평가 모델, 사기탐지시스템, 장바구니 분석, 최적 포트폴리오 구축 등과 같은 산업 분야에 광범위하게 사용 됨

## 2 데이터 마이닝

### 연관성 분석

- ▶ 거래나 사건을 포함하는 일련의 데이터로부터 연관 규칙을 발견하고 둘 이상의 품목들 간의 상호 연관성을 파악
- ▶ 장바구니 분석 또는 친화성 분석 방법 등

예: 맥주와 기저귀의 연관성

대형마트의 구매 패턴을 분석한 결과 주말에 아기용  
기저귀를 구매하러 온 아버지들이 동시에 맥주를 구매,  
이 패턴을 분석하여 월마트에서 기저귀와 맥주 패키지  
판매를 통한 3배 매출 증가 효과 달성

## 2 데이터 마이닝

### 군집 분석

- ▶ 이질적인 집단을 몇 개의 동질적인 소집단으로 세분화 하는 작업
- ▶ 특징: 사전에 정의된 집단이 없음
- ▶ 여러 집단의 데이터들이 섞여 있고 각 데이터 소속 집단을 모르는 경우 유사한 속성을 갖는 데이터의 군집을 찾는 분석 방법
- ▶ 주어진 데이터 중 유사한 것들만 몇몇의 집단으로 그룹화하여 각 집단의 성격을 파악하고 데이터 전체의 구조에 대한 이해를 돋도록 함

## 2 데이터 마이닝

### 의사결정 나무

- ▶ 분류 문제를 해결하기 위해 매우 강력하고 유용한 데이터 마이닝 알고리즘
- ▶ 분류를 하기 위한 목표 변수에 영향을 줄 수 있는 입력 변수들을 이용하여 최적의 분류를 위한 의사결정 규칙 생성

## 2 데이터 마이닝

- ▶ 클러스터 분석, 차원 압축 등을 주로 이용하며 그림을 결과를 표현하여 사람이 특징을 파악할 수 있도록 함

| 장점  | 단점   |
|---|--|
| 정보의 연관성을<br>파악하고 가치 있는<br>정보를 만들어<br>의사결정을 하고 이익을<br>극대화 시킴 | 자료에 의존하여 현상<br>해석 및 개선으로 인해<br>자료가 충실하지 못할<br>경우 오류 존재 |


## 2 | 클러스터 분석과 K-평균 알고리즘

### 1 클러스터 분석

- ▶ 자율 학습의 대표적인 접근 방법
- ▶ 평면상에 그려져 있는 점들을 그룹으로 분류
- ▶ 그룹으로 만들 때 점들 사이가 어느 정도 떨어져 있는지 측정 지표
- ▶ 클러스터란 비슷한 특성을 가진 데이터들의 집단
- ▶ 효율성
  - 수백 만의 데이터를 직접 확인하지 않고 각각 클러스터의 대표값만 확인하여 전체 데이터의 특성 파악 가능

### 1 클러스터 분석

- ▶ 평면 상에 점을 그림
- ▶ 데이터 특성 고려한 클러스터 정의
- ▶ 데이터 집단의 대표점 검색
- ▶ 데이터 마이닝의 대표적 예



[클러스터 분석 예]

### 1 클러스터 분석

#### ▶ 기법


|         |  |
|---------|--|
| 파티셔닝    | data를 구간구간으로 나눠서 그들의 중심을 계산  |
| k-평균    | 각 구간을 나눈 다음 중심을 찾고 중심을 기준으로 구간을 다시 나누고 변경 사항이 있을 경우 다시 중심을 찾아가는 방식 |
| k-중간점   | k-mean의 경계에 약한 단점을 보완. 중심 대신 중심객체를 사용                              |
| clara   | 샘플링 k-medoids(중앙 객체)   |
| clarans | 근처에 있는 데이터들끼리 샘플링  |

### 2 k-평균 알고리즘

- ▶ 클러스터 분석 시 자주 사용하는 방법
- ▶ 과정
  - 우선 전체를  $k$ 개의 그룹으로 나눔
  - 각 점에 무작위로 그룹을 할당한 다음 그룹 각각의 중심과의 거리를 계산
  - 어떤 그룹에 속해 있는 점이 다른 그룹과 더 가깝다면 해당 점을 거리가 가까운 그룹으로 변경
  - 이러한 작업을 반복해서 가까운 점끼리 묶어  $k$ 개의 그룹을 분류

### 2 k-평균 알고리즘

- ▶ 임의의 점들의 분포를 이용하여 k개의 그룹으로 분리
- ▶ 중심의 대표점을 선택
- ▶ 각각의 점들과 그룹의 대표점들 간의 거리 측정
- ▶ 재 그룹화



[K-평균 알고리즘 예]

### 2 k-평균 알고리즘

#### ▶ 단점

- 그룹의 중심점만 기준으로 삼다가 잘못된 그룹으로 할당할 수 있음
- 계산 시간이 길어짐

#### ▶ 해결 방법

- k-평균 알고리즘으로 여러 번 그룹을 생성하여 가장 좋은 결과를 채용
- 그룹 생성 전 중심점을 되도록 떨어져 있게 설정하는 k-평균++ 알고리즘 사용

k-평균++ 알고리즘: k-means 알고리즘의 초기값을 선택하는 알고리즘


### 2 k-평균 알고리즘

- ▶ 초기 그룹의 수인  $k$ 는 경험적으로 결정할 수도 있고 계산으로 산출하여 결정할 수도 있음
- ▶  $k$  결정 시 디리클레 모델 사용
  - 혼합 디리클레 모델은 베이즈 모델 기반의 접근 방식
  - 디리클레 분포가 다항분포의 결합 사전 분포라는 점을 이용

다항분포는 각 사건의 확률을 나타내는 분포이며 디리클레 분포는 발생하는 사건의 개수를 나타내는 분포

### 2 k-평균 알고리즘

- ▶ 혼합 디리클레 모델로 데이터를 그룹에 할당할 때 보통 기존의 가까운 그룹에 할당
- ▶ 그룹 할당 과정을 EM 알고리즘으로 반복 실행하면 그룹 개수와 그룹 각각에 할당하는 데이터 분포 관찰 가능



### 3 | GMM 알고리즘


#### 1 가우시안 혼합 모델 개념

- ▶ 가우시안 분포가 여러 개 혼합된 클러스터링 알고리즘
- ▶ 자연적인 현상 표현에 좋은 모델로 데이터 마이닝, 패턴 인식, 통계 분석 등에 광범위하게 적용
- ▶ 여러 개의 가우시안 분포로부터 생성(수집)된 데이터들을 학습하여 각 데이터들이 어떤 가우시안 분포에서 생성된 것인지 확률로 추정 가능
- ▶ 새로운 데이터가 입력될 경우 동일한 과정으로 클러스터링이 가능

#### 1 가우시안 혼합 모델 개념

##### ▶ K-means 클러스터링

- 클러스터 n의 중심에 있는 데이터 점 A와 외곽 끝에 있는 데이터 점 B에 동일한 클러스터링 값이 부여 (예:  $Z = [1, 0, 0]$ )



## 1 가우시안 혼합 모델 개념

▶ 3개의 클래스는 정해진 것이 아니라 추정되는 것으로 이것을 잠재 변수라 함

| 입력데이터                | 클래스             | 클래스 확률                   |
|----------------------|-----------------|--------------------------|
| $x_A = [0.02, 0.08]$ | $r = [1, 0, 0]$ | $\gamma = [0.9, 0.1, 0]$ |
| $x_B = [0.96, 0.98]$ | $[1, 0, 0]$     | $[0.5, 0.4, 0.1]$        |

3개의 클러스터가 존재할 경우

▶  $\gamma$

- 클러스터  $k$ 에 속할 확률
- 어떤 클러스터에 얼마나 기여하고 있는가  
→ 부담율(Responsibility)

## 1

## 가우시안 혼합 모델 개념

$$p(x) = \sum_{k=0}^{K-1} \pi_k N(\mathbf{x}|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$$

가우스 함수

클래스 확률


중심 벡터:  $\boldsymbol{\mu}_k = (\mu_{k0}, \mu_{k1})$  각 가우스 분포 k의 중심

공분산 행렬:  $\boldsymbol{\Sigma}_k = \begin{bmatrix} \sigma_{k00} & \sigma_{k01} \\ \sigma_{k10} & \sigma_{k11} \end{bmatrix}$  각 가우스 분포 k의 퍼짐


혼합 계수:  $\boldsymbol{\pi}_k, 0 \leq \boldsymbol{\pi}_k \leq 1, \sum_{k=0}^{K-1} \boldsymbol{\pi}_k = 1$  각각의 가우스 분포의 크기 비율

## 2 GMM의 예


- ▶ 세 개의 gaussian 분포를 이용하여 데이터를 생성



[기저가 된 3개의 가우시안 분포]



[생성된 데이터]




[실제 우리가 보는 데이터]

- ▶ 3가지 분포의 평균, 매개변수, 가중치를 구하여 혼합 모델을 구축
- ▶ 매개 변수 추정에 대한 다양한 알고리즘을 통해 GMM 모델 생성

## 2 GMM의 예

- ▶ 매개변수 추정을 통해 생성한 GMM 모델



- ▶ 왼쪽은 데이터 빈도, 오른쪽은 확률 밀도 함수
- ▶ 데이터 중 (-1, 0) 을 클러스터링 하고자 할 경우, 어떤 3개의 정규 분포 중 어느 분포에서 발생할 확률이 가장 높은지를 산출하여 클러스터링

## 3 GMM의 매개변수 추정

### ▶ 목적

- 관측되지 않는 클러스터 분포의 확률 분포와 각각의 클러스터에서의 gaussian 정규분포 매개 변수를 모두 추정하는 것

### ▶ 단점

- 확률분포 함수가 선형대수 방법으로 쉽게 구할 수 없는 복잡한 형태를 가진다는 점

### ▶ 매개 변수

- 잠재변수(latent variable) → 클러스터의 개수
- 부담율(responsibility)

## 3 GMM의 매개변수 추정

### 잠재 변수

▶ 관찰은 안되지만 데이터에 영향을 준 변수를 잠재 변수 또는 숨은 변수

### 예

- 곤충의 질량과 크기를 나타내는 입력 데이터가 있는데 같은 곤충이라 생각하고 수집한 데이터를 클러스터링 해 보니 3개의 클러스터가 있는 것으로 추정
- 같은 곤충에 3가지 종류가 있을 수 있다고 해석이 가능
- 3개의 클러스터가 3개의 클래스라는 존재를 암시

## 3 GMM의 매개변수 추정

### 부담율(responsibility)

- ▶ 관찰되지 않은 잠재 변수의 추정치가 어떤 클러스터에 포함될 것인지를 알려 주는 조건부 확률

$$\gamma_{ik} = p(z_i = k|x_i) = \frac{p(z_i = k)p(x_i|z_i = k)}{p(x_i)} \quad z_i: \text{class(또는 cluster)}$$

$$= \frac{p(z_i = k)p(x_i|z_i = k)}{\sum_{k=0}^{K-1} p(x_i, z_i = k)} = \frac{p(z_i = k)p(x_i|z_i = k)}{\sum_{k=0}^{K-1} p(z_i = k)p(x_i|z_i = k)}$$

- ▶  $\gamma_{ik}$
- 데이터  $x_i$ 가 클러스터  $k$ 에서 생성되었을 확률
  - 확률적 추정값으로 0에서 1사이의 실수값

#### 4 EM 알고리즘

- ▶ 1958년 Hartley에 의해서 제안된 군집 알고리즘
- ▶ K-Means 알고리즘과 마찬가지로 초기 모델을 생성한 후 반복 과정을 통하여 최적화된 모델을 생성
- ▶ 반복 과정을 통하여 각 데이터들이 혼합 모델(Mixture Model)에 속할 가능성(Probability)을 조정하여 최적의 모델을 생성
- ▶ K-Means 알고리즘에서는 유clidean 거리 함수를 사용하는 반면에 EM 알고리즘은 log-likelihood 함수를 사용하여 모델의 적합성을 평가
- ▶ EM 알고리즘은 최적해로 수렴한다는 것이 증명
- ▶ EM은 초기 해에 따라 최종 해가 달라지는 욕심 알고리즘(Greedy algorithm)이고, 전역 최적 해가 아닌 지역 최적 해로 수렴할 수도 있음

#### 4 EM 알고리즘

- ▶ E Step(Expectation Step)
  - $\pi, \mu, \Sigma$  초기화로 부담율  $\gamma$ 를 산출
- ▶ M Step(Maximization Step)
  - 현시점의  $\gamma$ 를 이용하여  $\pi, \mu, \Sigma$ 를 산출
- ▶ 각 단계가 임계치보다 작을 때까지 반복

$\pi$ : 클러스터의 혼합 계수\*  
 $\mu$ : 클러스터의 중심 벡터  
 $\Sigma$ : 클러스터의 공분산 행렬

$$y = a * \exp\left(-\frac{(x - \mu)^2}{\sigma^2}\right)$$


*Gauss Function*

## 4 EM 알고리즘

### ▶ 초기화

- $\pi, \mu, \Sigma$ 의 초기화와  
데이터의 분포를 시각화

각 클러스터에 대한 데이터의 부담율




[초기화 모델]

## 4 EM 알고리즘

### ▶ Expectation Step

- $\pi, \mu, \Sigma$ 로 부담율  $\gamma$ 를 산출
- $$\gamma_{nk} = \frac{\pi_k N(\mathbf{x}_n | \mu_k, \Sigma_k)}{\sum_k^K N(\mathbf{x}_n | \mu_k, \Sigma_k)}$$
 가우스 함수
- 각 가우스 함수 값을 계산한 후 합이 1이 되도록 정규화



[데이터의 부담율을 이용하여 표시된 모델]

## 4 EM 알고리즘

### ▶ Maximization Step(1)

- 각 클러스터에 대한 부담율의 합을 산출

$$N_k = \sum_{n=0}^{N-1} \gamma_{nk} \quad \mu_k^{new} = \frac{1}{N_k} \sum_{n=0}^{N-1} \gamma_{nk} x_n \quad \triangleleft \text{ 중심 벡터 갱신}$$

- 산출된 값을 이용하여 혼합율 갱신


$$\pi_k^{new} = \frac{N_k}{N} \quad \Sigma_k^{new} = \frac{1}{N_k} \sum_{n=0}^{N-1} \gamma_{nk} (x_n - \mu_k^{new})^T (x_n - \mu_k^{new})$$

△ 공분산 갱신

## 4 EM 알고리즘

### ▶ Maximization Step(2)

- 갱신된 혼합율과 중심벡터, 공분산을 이용하여 모델 갱신




[1회 EM 스텝을 수행 한 후 클러스터링 된 데이터들]

## 4 EM 알고리즘

### ▶ 반복 과정

- 20회 반복을 통해 클러스터의 중심으로 *gauss* 함수가 이동하여 수렴
- K-means와는 다르게 클러스터의 경계 부분에 확률적으로 데이터가 표시되는 것을 확인
- K-means와 마찬가지로 매개 변수의 초기값에 따라 변화
- 클러스터링의 평가를 위해 k-means는 왜곡 척도를 사용하였고 GMM은 가능성도를 사용



[20회 수행 한 후 클러스터링 된 데이터들]

## 4 EM 알고리즘


### ▶ 가능성

- 가능성은 모든 데이터 점  $X$ 가 모델에서 생성된 확률
- 로그를 취한 후 -1을 곱한 값
- 가능성나 로그 가능성을 최적화할 때에는 확률을  
극대화하기 때문에 -1을 곱한 음의 로그 가능도를  
오차 함수로 정의

## 4 EM 알고리즘

### ▶ 가능성 오차 함수

- 스텝의 반복에 따라 가능성 값을 측정
- 음의 로그 가능성 계산 알고리즘은 반복 계산의 종료 조건으로도 사용이 가능
- 다양한 초기값을 이용한 클러스터링으로 음의 로그 가능성 값이 가장 작은 것이 좋은 결과임을 판단하는 기준



[가능도 오차 함수]

## 5 GMM 모델 응용 예(1)

### 퍼지 영상 분할(Fuzzy image segmentation)

- ▶ 교통 분야의 영상 처리 시 사고와 혼잡의 구분을 위해 GMM 모델을 적용
- ▶ 기존 영상 처리나 CV에서는 하나의 픽셀을 하나의 패턴에만 할당
- ▶ 만약 패턴들이 *gaussian* 분포라면, 퍼지 영상 분할은 *gaussian* 혼합 모델 분포를 따름
- ▶ 공간적으로 정규화 된 혼합 모델로서 더 현실적이고 계산적으로 효율적인 분할 방법

## 5 GMM 모델 응용 예(1)

### 문서의 주제(Topic Model)

- ▶ 문서가  $N$ 개의 서로 다른 단어와 전체 크기가  $V$ 인 어휘로 구성되어 있고, 각 단어는  $K$ 개의 주제 중 하나에 해당한다고 가정
- ▶ 이러한 단어들의 분포는  $K$  개의 서로 다른  $V$  차원 범주형 분포(Categorical distribution)의 혼합 모델로 표현
- ▶ 사전 분포(Prior distribution)는 아주 작은 수의 단어만 0이 아닌 확률을 가지고 있는 스파스 분포(Sparse distribution)를 만들기 위해 토픽 분포를 묘사하는 매개변수 사용
- ▶ 자연적 집단화(natural clustering)를 이용하기 위해, 몇몇 종류의 추가 조건은 단어들의 토픽 유사성(identities)을 사용