

# 1 | 앙상블 학습

## 1 학습 포인트

- ▶ 앙상블 학습
- ▶ 배깅(Bagging)
- ▶ 부스팅(Boosting)

## 2 앙상블 학습(Ensemble learning)

### ▶ 정의

- 학습 알고리즘(Learning algorithm)들을 따로 쓰는 경우에 비해 더 좋은 예측 성능을 얻기 위해 다수의 학습 알고리즘을 사용하는 방법

### ▶ 통계 기반 머신 러닝으로 만든 학습기와 분류기

- 분류와 식별 실행 시 학습기 하나에서 원하는 성능을 얻을 수 있도록 설계  
→ 학습기 수가 적은 모델 구축 시 사용
- 사람의 학습기 동작 이해를 위해 가능한 구조를 단순하게 설계하기 때문

## 2 앙상블 학습(Ensemble learning)

- ▶ 학습기 하나로 원하는 성능을 얻을 수 없는 경우  
앙상블 학습이 효율적
- ▶ 개별로 학습한 여러 학습기를 조합해 일반화 성능 향상
  - 더 많은 미지의 문제에 대응 가능
- ▶ 기계 학습과 신경망, SVM 알고리즘
  - 장점  
: 정교화되고 대규모 화되어 예측 성능이 매우 뛰어남
  - 단점  
: 학습의 대상이 되는 파라미터의 수가 많아 학습에 시간이 많이 걸리고, 최적해를 찾기도 어려움
  - 과도적합의 문제로 인한 일반화 오차가 증가

## 2 앙상블 학습(Ensemble learning)

- ▶ 앙상블 학습 시 고려할 사항
  - 어떤 학습기를 사용할 것인가  
: 비교적 간단하면서 차별화 되는 분류기들을 선택
  - 어떻게 결합할 것인가  
: 학습이 완료된 학습기들로부터 얻어지는 인식 결과를  
각 학습기의 특성을 고려하여 효과적으로 결합

## 2 앙상블 학습(Ensemble learning)

- ▶ 복수 개의 분류기를 학습 하는 방법
  - 학습 알고리즘의 차별화
  - 모델 선택과 관련 파라미터의 차별화
  - 학습 데이터의 차별화
- ▶ 분류기를 결합하는 방법
  - 병렬적 결합
  - 순차적 결합

## 2 앙상블 학습(Ensemble learning)

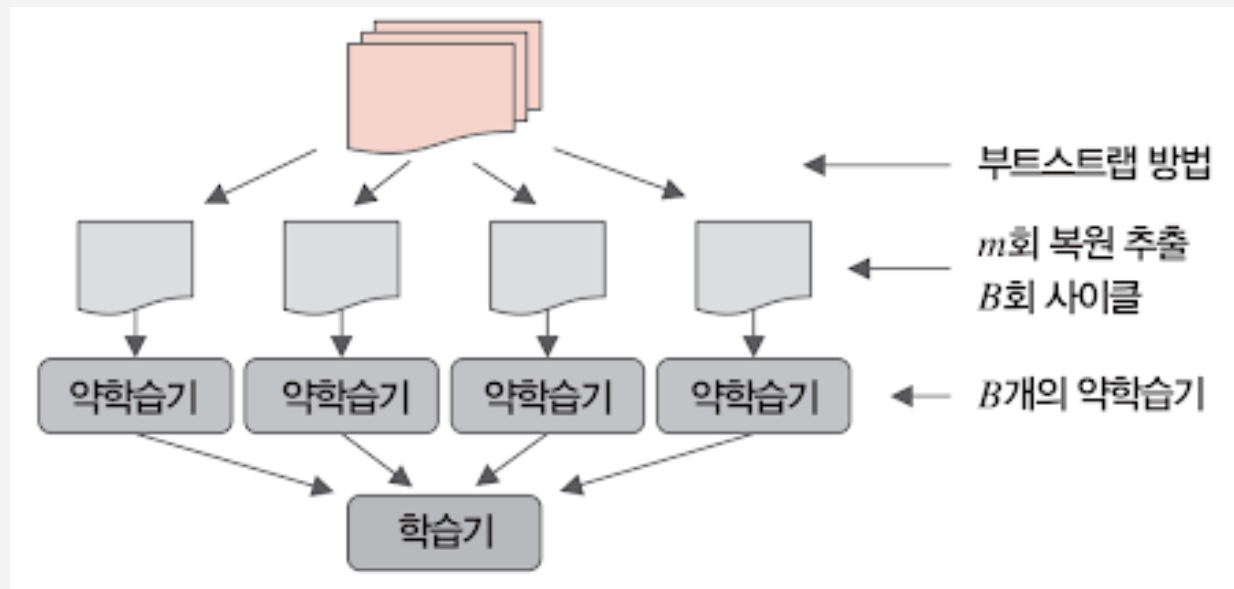
- ▶ 앙상블 학습
  - 필터링에 의한 학습
  - 리샘플링에 의한 학습
  - 가중치 조정에 의한 학습

## 3 배깅(Bagging)

- ▶ 앙상블 학습 중 하나의 학습 방법
- ▶ 부트스트랩 방법을 이용해 학습 데이터에서  $m$ 개의 복원 추출을  $B$ 회 만큼 반복
  - 작게 나눈  $m$  개의 데이터를 포함하는  $B$  회의 학습 데이터 생성
- ▶ 각각의 학습 데이터로 학습 하면서 약학습기  $h$ 를 구축한 후 통합하여  $H$ 를 생성
- ▶  $H$ 는 학습 데이터의 식별이나 확인에는 가장 우수한 결과를 선택
- ▶ 회귀일 경우는  $h$ 의 평균을 이용



## 3 배깅(Bagging)



※ 출처 : 처음 배우는 인공지능, 다다 사토시, 한빛미디어, 2017

## 3 배깅(Bagging)

- ▶ 부트스트랩 방법과 방식
  - 데이터를 샘플링 하여 의사 데이터 세트를 생성하는 리샘플링 방법
  - 통계의 편향이나 분산을 추정할 때 사용
  - 예) 어떤 집단에서 값을 측정했을 때,  
그 중에서 임의로 100개를 뽑아서  
평균(Sample mean)을 구함
  - 사용 목적
    - 원 데이터의 확률 분포를 모르는 경우
    - 측정된 샘플이 부족한 경우

## 3 배깅(Bagging)

### ▶ 랜덤 포레스트와의 차이

- 공통점
  - 랜덤 포레스트 역시 배깅과 같이 무작위 데이터를 추출한 후 작은 데이터 세트에서 학습을 실행
- 차이점
  - 배깅은 학습 데이터의 설명 변수를 모두 사용하며 랜덤 포레스트는 설명 변수도 무작위로 추출

## 4 부스팅

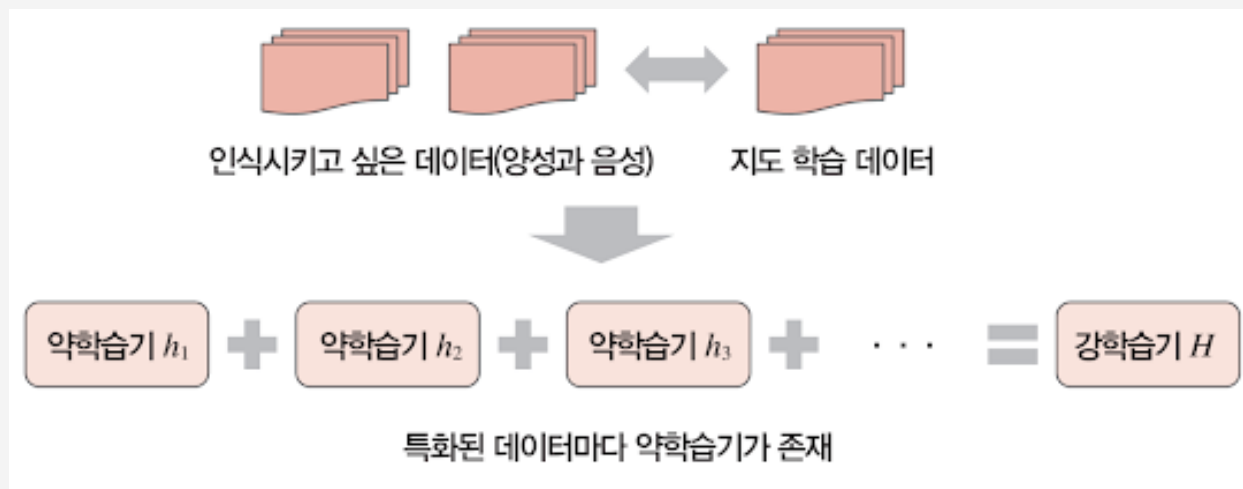
### ▶ 정의

- 약학습기를 순서대로 하나씩 결합해  
강학습기를 얻는 방법
- 배킹은 여러 개 약학습기(Weak learner)를  
동시에 선택한 후 공평하게 이용

### ▶ 사용 방법

- 기대하는 인식 결과를 내고 싶은 데이터 세트와  
그렇지 않은 데이터 세트로 분리
- 특화된 데이터마다 만드는 약학습기를 순서대로 결합
- 인식 결과의 정확도가 높은 강학습기를 얻을 수 있음

## 4 부스팅



※ 출처 : 처음 배우는 인공지능, 다다 사토시, 한빛미디어, 2017

## 4 부스팅

- ▶ 에이다부스트 알고리즘
- 대표적인 부스팅 알고리즘
  - 2개의 값 분류에 관한 약학습기 구축 알고리즘
  - 부트스트랩 방법 등을 이용해 약학습기를 여러 개 구축하여 약학습기를 확률분포  $D$ 에 따라 선택

$X$  : 양성과 음성을 정답으로 가진 지도 학습 데이터

$Y$  : 정답 데이터

$x_1, \dots, x_n \in X, y_1, \dots, y_n \in Y = \{-1, 1\}$

$D_1 = 1/m, t = 1 \dots T$ 식으로 단계를 늘림  $D_t(i) (i = 1, \dots, m)$

## 4 부스팅

### ▶ 에이다부스트 알고리즘

#### ■ 반복 과정 순서

- 여러 개 약학습기의 오류율  $\varepsilon_t$ 를 계산하고  $\varepsilon_t$  최소인 약학습기  $h_t$  선택
- $\varepsilon_t > 0.5$  가 되면 종료
- $h_t$ 의 중요도  $a_t$ 를 계산
- 가중치를 업데이트

$$\varepsilon_t = \sum_{i: h_t(x_i) \neq y_i} D_t(i)$$

$$a_t = \frac{1}{2} \ln\left(\frac{1 - \varepsilon_t}{\varepsilon_t}\right)$$

$$D_{t+1}(i) = \frac{D_t(i) \exp(-a_t y_i h_t(x_i))}{Z_i}$$

## 4 부스팅

### ▶ 에이다부스트 알고리즘

- 오류율
  - 선택한 약학습기의 인식률이 얼마나 높은지를 표현
- 오류율이 0.5를 넘으면 예측보다 정밀도가 낮다는 의미로 약학습기 생성을 종료
- 중요도를 계산한 후 그 값을 이용해 가중치  $D$ 를 업데이트
  - 정답과 일치하는 데이터의 가중치를 줄임
  - 정답과 불일치하는 데이터는 가중치를 늘임



## 4 부스팅

### ▶ 에이다부스트 알고리즘

- $Z_i$ 는 업데이트 후  
가중치  $D_{t+1}(i)$ 의 합을 1로 만드는 값
- $T$  개의 약학습기 식별 결과를 중요도로 설정한 후  
가중치를 적용하여 더하면 강학습기  $H$ 를 완성

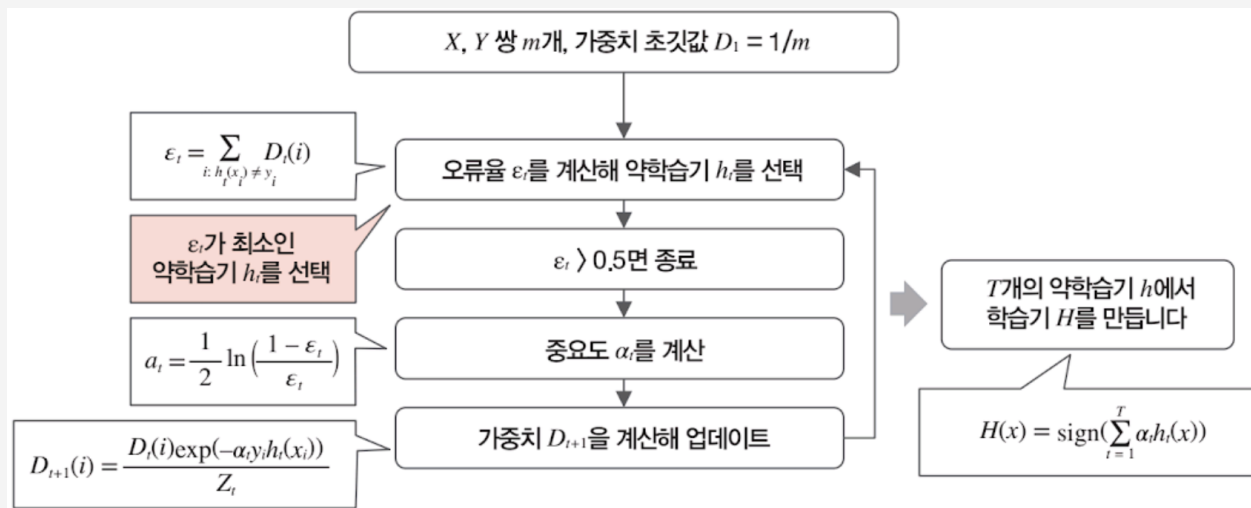
[학습기  $H$ 의 식]

$$H(x) = \text{sign}\left(\sum_{t=1}^T \alpha_t h_t(x)\right)$$

※ 출처 : 처음 배우는 인공지능, 다다 사토시, 한빛미디어, 2017

## 4 부스팅

### [에이다부스트 알고리즘]



※ 출처 : 처음 배우는 인공지능, 다다 사토시, 한빛미디어, 2017

## 4 부스팅

- ▶ 에이다부스트 알고리즘
  - 멀티 클래스 에이다부스트 알고리즘
    - 여러 개의 값 분류에 적용
  - MadaBoost, U-Boost
    - 강학습기  $H$ 의 식에서  $\sum(-\alpha_t h_t(x_i))$ 를 손실 함수로 고려하여 에이다부스트 알고리즘을 확장

## 2 | 강화 학습

### 1 학습 포인트

- ▶ 강화 학습 이론
- ▶ 확률 시스템
- ▶ 보상과 가치 함수
- ▶ 벨만 방정식
- ▶ Q 학습

### 2 강화 학습 이론

- ▶ 뉴로모픽 컴퓨터
  - 환경과의 상호 작용으로 자율적으로 학습하는 것을 목표로 둔 시스템
  - 현실적으로는 사람이 미리 지식 기반, 규칙, 통계 모델 등에 기반을 둔 학습기를 준비
  - 준비된 학습기를 참조해 사람이 해야 할 평가를 대신하는 형태
- ▶ 강화 학습
  - 기계가 사람처럼 미지의 데이터에도 대응하도록 스스로 학습기를 변화시킬 수 있는 구조

### 2 강화 학습 이론

- ▶ 강화 학습 이론
  - 시행 착오를 통해 보상을 받아 행동 패턴을 학습하는 과정을 모델화 한 것
- ▶ 강화
  - 심리학의 조작적 조건화에 기반을 두고 자발적인 행동의 빈도를 증가시키는 것

### 2 강화 학습 이론

#### 심리학의 조작적 조건화

자발적인 시행착오의 결과로 얻은 보상으로 행동을 결정하는 것을 말함, 스위치를 누르면 먹이가 나오는 스키너 상자를 이용한 실험이 대표적으로 비둘기 같은 동물은 먹이라는 보상으로 스위치를 누르는 것을 기억



### 3 확률 시스템

- ▶ 확률 시스템
  - 마르코프 결정 과정이라는 불확실성을 전제하는 시스템
  - 데이터를 지속해서 추가 투입하는 스트리밍 처리로 머신러닝을 실행
  - 배치 처리 머신러닝과 비교하여 온라인 머신 러닝이라고 함
- ▶ 확정 시스템
  - 동적 계획법 등 배치 처리 최적화 기법을 이용하는 대상
  - 일괄 학습 또는 오프라인 머신 러닝

### 3 확률 시스템

[확정 시스템과 확률 시스템]

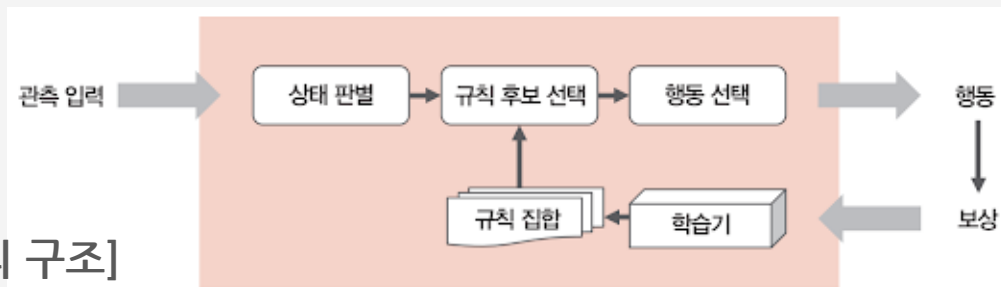


※ 출처 : 처음 배우는 인공지능, 다다 사토시, 한빛미디어, 2017

### 4 정책과 강화 학습

- ▶ 외부에서 입력 데이터를 받은 에이전트가 학습기에서 생성된 규칙들 속에서 규칙을 선택한 후 외부로 대상으로 행동
- ▶ 행동하는 에이전트는 외부에서 보상을 얻을 수 있으며 이를 통해 학습기를 업데이트

[강화 학습의 구조]



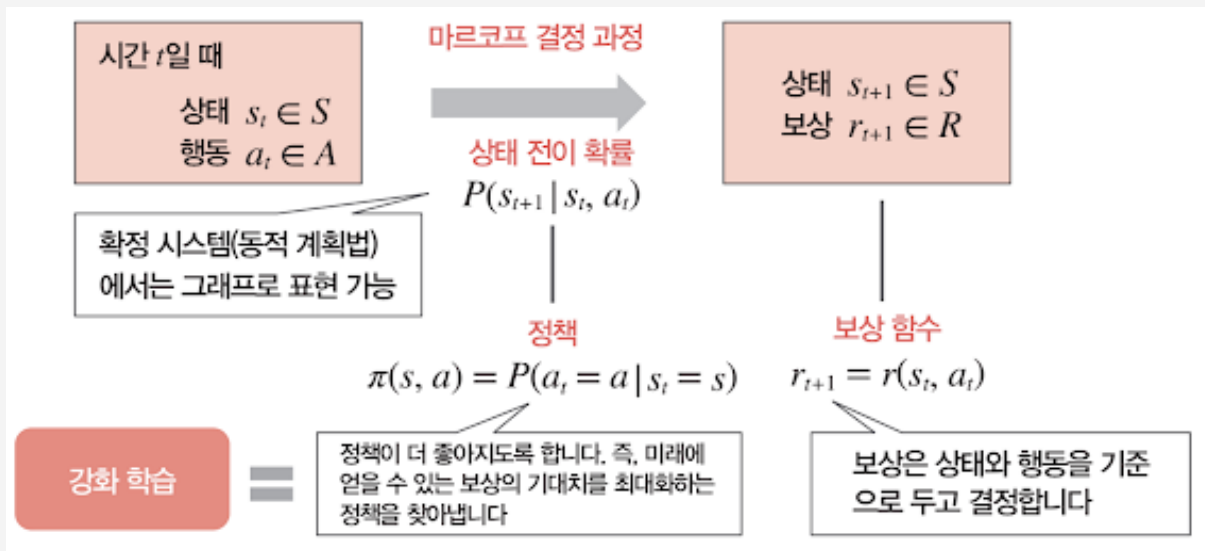
※ 출처 : 처음 배우는 인공지능, 다다 사토시, 한빛미디어, 2017

### 4 정책과 강화 학습

- ▶ 에이전트가 다음에 취할 행동은 확률로 결정
- ▶ 해당 시점의 규칙에 따르는 지침을 정책 :  $\pi$ 로 표시
- ▶ 강화 학습은 시간  $t$ 에서의 상태와 행동에 의존하는 마르코프 결정 과정에 기반을 두고 학습 진행
- ▶ 행동 결과로 보상  $r_{t+1}$  부여

### 4 정책과 강화 학습

[마르코프 결정 과정과 강화 학습]



※ 출처 : 처음 배우는 인공지능, 다다 사토시, 한빛미디어, 2017

### 5 보상과 가치 함수

- ▶ 누적 보상
  - 최초 상태에서 최종 상태까지 얻은 보상의 합계
  - $T \rightarrow \infty$  시 발산 가능성으로 할인 누적 보상 사용

[할인 누적 보상 식]

$$R_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k+1}$$

### 5 보상과 가치 함수

- ▶ 가치 함수
  - 누적 보상을 극대화하려고  
미래의 상태와 행동을 평가하는 함수

### 5 보상과 가치 함수

#### ▶ 가치 함수 종류

- 상태 가치 함수
  - 상태  $s$ 가 정책  $\pi$ 를 따를 때 얻을 수 있는 할인 누적 보상 기대치
- 행동 가치 함수
  - 정책  $\pi$ 에 따라 상태  $s$ 에서 행동  $a$ 를 얻을 수 있는 할인 누적 보상의 기대치
- 벨먼 방정식
  - 마르코프 결정 과정에서 상태 가치 함수  $V_{\pi}(s)$ 의 재귀적 표현



### 5 보상과 가치 함수

#### ▶ Q 학습

- 강화 학습의 대표적인 예
- 최적 행동 가치 함수  $Q^*(s, a)$ 의  $Q$  값을 추정해 최선의 정책을 결정
- TD 오차 : 다음 상태의  $Q$  와 현재  $Q$  값과의 차이

#### ▶ Q 학습 종류

- 그리디 방법
- 랜덤 방법
- $\epsilon$ - 그리디 방법
- 볼츠만 선택

### 5 보상과 가치 함수

- ▶ Q 학습종류
  - 그리디 방법
    - 탐욕 알고리즘이라고도 하며  
 $Q$  값이 가장 높은 행동만을 선택
  - 랜덤 방법
    - 행동을 무작위로 선택

### 5 보상과 가치 함수

- ▶ Q 학습종류
  - $\epsilon$ -그리드 방법
    - 랜덤과 그리디 방법을 결합한 방법
  - 볼츠만 선택
    - $Q$  값이 크면 선택 받기 쉬우며  
 $Q$  값이 작으면 선택 받기 어렵게 하는 방법

### 5 보상과 가치 함수

- ▶ Deep Q-network
  - TD 오차 계산 시 신경망으로 최적화 하여 딥러닝에 대응시킨 것
  - 구글 자회사인 딥마인드가 개발
  - 벽돌 깨기, 팩맨, 알파고 훈련에 이용

# 3 | 전이 학습

### 1 학습 포인트

- ▶ 도메인과 도메인 적응
- ▶ 메타 학습

## 2 도메인과 도메인 적응

- ▶ 새로운 작업 시 기존 작업과 달리 학습용 데이터가 많지 않거나 일반화 성능을 이용해서 해결하기 어려움
- ▶ 도메인 적응
  - 전이 학습으로 문제를 해결하는 방법
  - 원 도메인
    - 이미 학습한 작업에 특화된 지식과 학습기 영역
  - 목표 도메인
    - 앞으로 대응해야 할 새로운 영역

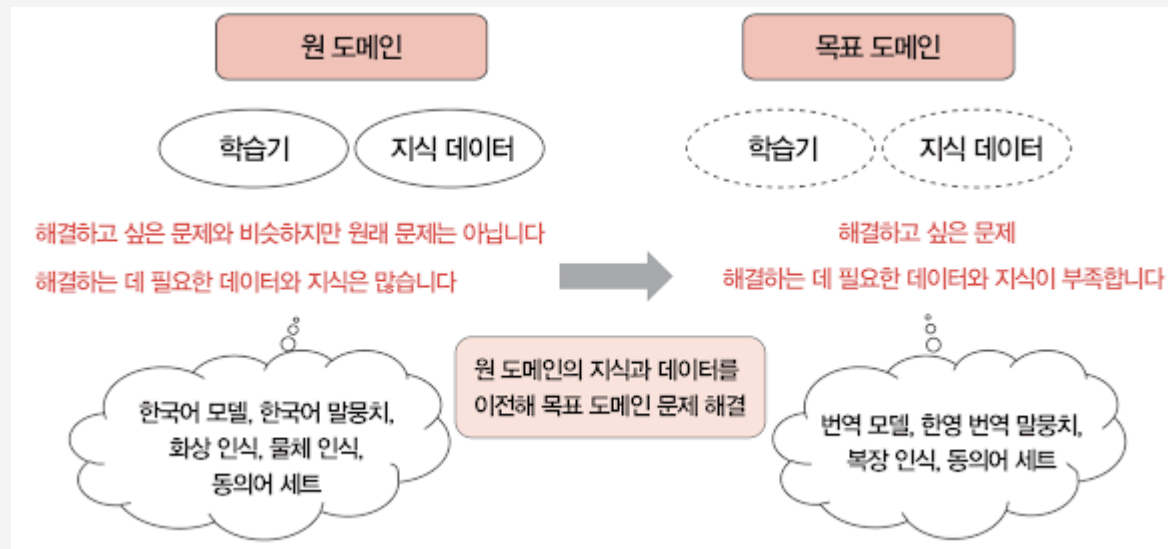
## 2 도메인과 도메인 적응

- ▶ 전이 학습
  - 새로운 작업을 효율적으로 해결하려고  
기존 작업에서 얻은 학습 데이터와 학습 결과를  
재사용하는 것
- ▶ 목표
  - 가급적 원 도메인의 정보를 최대한 활용하면서  
목표 도메인을 잘 지원하는 학습기를 효율적으로  
얻는 것
- ▶ 예
  - 원 도메인이 한국어에 관한 언어 모델일 때  
한영 번역 모델을 구축



## 2 도메인과 도메인 적응

### [전이 학습 구성]



※ 출처 : 처음 배우는 인공지능, 다다 사토시, 한빛미디어, 2017

## 2 도메인과 도메인 적응

- ▶ 전이 학습 구성
- 귀납 전이 학습
  - 변환 전이 학습
  - 자기 교시 학습
  - 자율 전이 학습

[전이 학습 종류]

		목표 도메인	
		라벨 있음	라벨 없음
원 도 메 인	라 벨 있 음	귀납 전이 학습	변환 전이 학습
	라 벨 없 음	자기 교시 학습	자율 전이 학습

※ 출처 : 처음 배우는 인공지능, 다다 사토시, 한빛미디어, 2017

## 2 도메인과 도메인 적응

- ▶ 전이 학습 구성
  - 지식을 보내는 소스 도메인의 처리와 지식을 받는 목표 도메인의 처리로 구분
  - 원 도메인
    - : 사례 기반 방법과 특징 기반 방법을 검토
  - 목표 도메인
    - : 원 도메인에서 정한 모델을 기반으로 대응

[전이 학습 접근 방법]

지식을 보내는 쪽(원 도메인)		지식을 받는 쪽(목표 도메인)
사례 기반	특징 기반	모델 기반
사례에 가중치 처리  <hr/> TrBagg(배깅의 전이 학습 버전) TrAdaBoost(AdaBoost의 전이 학습 버전) 공변량 시프트	특징 공간을 변환  <hr/> 도메인 사이 스펙트럼 분류 유사도 학습	원 도메인의 데이터를 그대로 받아 목표 도메인에서 변환하는 모델 채용  <hr/> 베이지 계층 모델 혼합 모델 신경망 Migratory-Logit

※ 출처 : 처음 배우는 인공지능, 다다 사토시, 한빛미디어, 2017

### 2 도메인과 도메인 적응

#### ▶ 전이 학습 구성

##### ■ 자율 전이 학습

- 원 도메인과 목표 도메인에 라벨이 없는 데이터를 이용하는 전이 학습
- 원 도메인에서 클러스터 분석을 실행해 얻은 거리와 목표 도메인 거리와의 관련성에서 2개의 도메인 사이에 매핑 수행
- 유사도 학습의 한 가지 방법

### 3 메타 학습

- ▶ No Free Lunch 정리
  - 특정 도메인에 매우 좋은 일반화 성능을 갖는 학습기라도 다른 도메인에는 적용이 어려울 수 있음
- ▶ 메타 학습
  - 학습 방법을 학습하는 것
- ▶ 예
  - 관측 데이터를 기반으로 둔 수많은 가설 공간과 모델 중 적절한 모델을 선택하는 학습기가 있다면 더 상위 도메인에 기반을 둔 학습기를 선택하려고 메타 지식을 습득해 학습기를 구축